

# SME0809 - Inferência Bayesiana - Distribuição Normal

Grupo 13 - Francisco Miranda - 4402962 - Heitor Carvalho - 11833351

Outubro 2021

```
library(tidyverse)
library(effectsize)
library(invgamma)
library(dados)
#remotes::install_github("cienciadedatos/dados")
set.seed(42)
```

## Caso 1: $\mu$ desconhecido e $\sigma$ conhecido

### Verossimilhança da distribuição

$$\mathcal{L}(y|\theta) = \prod_{i=1}^n p(y_i|\theta) = \prod_{i=1}^n e^{-1/2\sigma^2(y_i-\theta)^2}$$

### A *priori* da distribuição

Nós parametrizamos  $p(\theta)$  de modo que  $\theta \sim \mathcal{N}(y_0, \tau_0^2)$  com média  $y_0$  e variância  $\tau_0^2$

$$p(\theta) \propto e^{(-1/2\tau_0^2)(\theta-y_0)^2}$$

### A priori não informativa de Jeffreys

A distribuição a *priori* de Jeffreys é dada por  $p(\theta) \propto \sqrt{J(n/\sigma^2)} \propto 1$

Sabemos que a Informação de Fisher de  $\theta$  através de  $y = y_1, \dots, y_n$  é definida como:

$$I(\theta) = E\left[-\frac{\partial^2 \log p(y|\theta)}{\partial \theta^2}\right]$$

Segue que:

$$\begin{aligned}
& -E\left[\frac{\partial^2}{\partial\theta^2}(-\log(2\pi\sigma^2)/2 - 1/2\sigma^2(\sum_{i=1}^n(y_i - \theta)^2))\right] \\
& = -E\left[\frac{\partial^2}{\partial\theta^2}(-\log(2\pi\sigma^2)/2 - 1/2\sigma^2(\sum_{i=1}^n(y_i^2 - 2\theta n\bar{y} + n\theta^2))\right] \\
& = -E\left[\frac{\partial}{\partial\theta}(-1/2\sigma^2(-2n\bar{y} + 2n\theta))\right] \\
& = -E[-1/2\sigma^2(2n)] \\
& = n/\sigma^2
\end{aligned}$$

## A *posteriori* da distribuição

A *posteriori* é computada assumindo-se que:

1. Cada observação é independentemente distribuída
2. Cada observação tem a mesma variância

$$p(\theta|y) = p(\theta) p(y|\theta) = p(\theta) \prod_{i=1}^n p(y_i|\theta) = e^{(-1/2\tau_0^2)(\theta-\mu_0)^2} \prod_{i=1}^n e^{(-1/2\sigma^2)(y_i-\theta)^2} = e^{(\frac{-1}{2})(1/\tau_0^2(\theta-\mu_0)^2 + \frac{1}{\sigma^2} \sum_{i=1}^n (y_i-\theta)^2)}$$

Desse modo, a distribuição a posteriori da média  $\theta$  depende apenas da média amostral  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ , sendo assim,  $\bar{y}$  é uma estatística suficiente.

Portanto, para  $n$  observações, a posteriori apresenta a seguinte distribuição:

$$p(\theta|y_1, \dots, y_n) = p(\theta | \bar{y}) = \mathcal{N}(\theta|y_n, \tau_n^2)$$

Sendo,

$$\mu_n = \frac{\tau_0^{-2}\mu_0 + n\sigma^{-2}\bar{y}}{\tau_0^{-2} + \sigma^{-2}}, \quad \text{e} \quad \tau_n^{-2} = \tau_0^{-2} + n\sigma^{-2}$$

Podemos reescrever  $p(\theta|y)$  como:

$$p(\theta|y_n) \propto e^{(-1/2\tau_n^2)(\theta-\mu_n)^2}$$

Logo, para uma distribuição Normal com variância conhecida, a média a *posteriori*  $\mu_n$  pode ser interpretada como a média ponderada da média a *priori* e o valor observado  $y = y_1, \dots, y_n$ , sendo os pesos proporcionais às precisões de cada um.

```

sample <- dados::penguins%>%
  filter(especie == "Pinguim-de-barbicha")%>%
  select(comprimento_bico)%>%
  drop_na()
sample2 <- sample %>% sample_n(2) %>% pull()
sample5 <- sample %>% sample_n(5) %>% pull()
sample15 <- sample %>% sample_n(15) %>% pull()
sample30 <- sample %>% sample_n(30) %>% pull()
sample <- sample %>% pull()

```

```

# gera a priori e a posteriori de uma normal com media desconhecida e sigma conhecido
norm <- function(samp, sigma = 40, mu, tau0 = 10000 ){

  n <- length(samp)
  xbar <- mean(samp)

  ver <- function(x) exp(- n/(2*sigma^2) * (xbar - x)^2)

  mu.post <- (tau0^(-2)*mu + n*sigma^(-2)*xbar)/ (tau0^(-2) + n * sigma^(-2))
  sigma.post <- (tau0^(-2) + n*sigma^(-2))^(1)

  theta <- seq(20, 60, 0.02)

  tibble(theta = theta,
          priori = dnorm(theta,mu,tau0),
          post = dnorm(theta,mu.post,sigma.post),
          ver = ver(theta),
          pred = dnorm(theta,mu.post,tau0+sigma),
          tau1 = sigma.post,
          mu1 = mu.post)

}

```

## Exemplo: Comprimento do bico dos pinguins

Escolheu-se o conjunto de dados *palmerpenquins* em sua versão traduzida. Como atributo de interesse escolhemos o comprimento do bico dos pinguins e nos limitamos a análise de uma espécie - nesse caso o **Pinguim-de-barbicha**. Existem 68 pinguins desta espécie em nosso dataset.

Sabe-se que para a distribuição do comprimento do bico dos pinguins tem-se que  $\sigma = 3,34$  e a média  $\theta = 48.8$ .

Quatro amigos, Cleiton, Eduarda, Larissa e Robertinho resolvem tentar estimar a média do comprimento do bico dos pinguins de barbicha. Para tanto, cada integrante do grupo resolve dar um palpite em relação a média e variância da distribuição.

Desse modo, Cleiton, que nunca foi a um zoológico e nunca viu um pinguim pessoalmente acredita que a distribuição seja próxima a  $\mathcal{N}(80,12)$ , Eduarda, que adora pinguins porém nunca viu um pessoalmente, acredita que  $\mathcal{N}(30,8)$ , Larissa que visita zoológicos com frequência acredita que  $\mathcal{N}(55,5)$  e Robertinho - biólogo que trabalha com pinguins acredita que  $\mathcal{N}(47,3)$ .

```

tibble(
  Prioris = c("Cleiton","Eduarda","Larissa", "Robertinho"),
  Media.pri = c(80, 30, 55, 47),
  SD.pri = c(20, 8, 5, 3),
  IC.025 = c(qnorm(0.025, mean = 80 , sd = 20),
             qnorm(0.025, mean = 30 , sd = 17.2),
             qnorm(0.025, mean = 55, sd = 12.1),
             qnorm(0.025, mean = 47, sd = 6.51)),
  IC.975 = c(qnorm(0.975, mean = 50.6 , sd = 22.2),
             qnorm(0.975, mean = 43.8 , sd = 17.2),
             qnorm(0.975, mean = 51.8, sd = 12.1),

```

```
qnorm(0.975, mean = 47.5, sd = 6.51)))%>%
knitr::kable(digits = 2, caption = "Resumo apriori dos quatro amigos para n = 68")
```

Table 1: Resumo apriori dos quatro amigos para  $n = 68$

| Prioris    | Media.pri | SD.pri | IC.025 | IC.975 |
|------------|-----------|--------|--------|--------|
| Cleiton    | 80        | 20     | 40.80  | 94.11  |
| Eduarda    | 30        | 8      | -3.71  | 77.51  |
| Larissa    | 55        | 5      | 31.28  | 75.52  |
| Robertinho | 47        | 3      | 34.24  | 60.26  |

Chegam duas amostras de bico de pinguins, uma com  $n = 5$ , outra com  $n = 15$

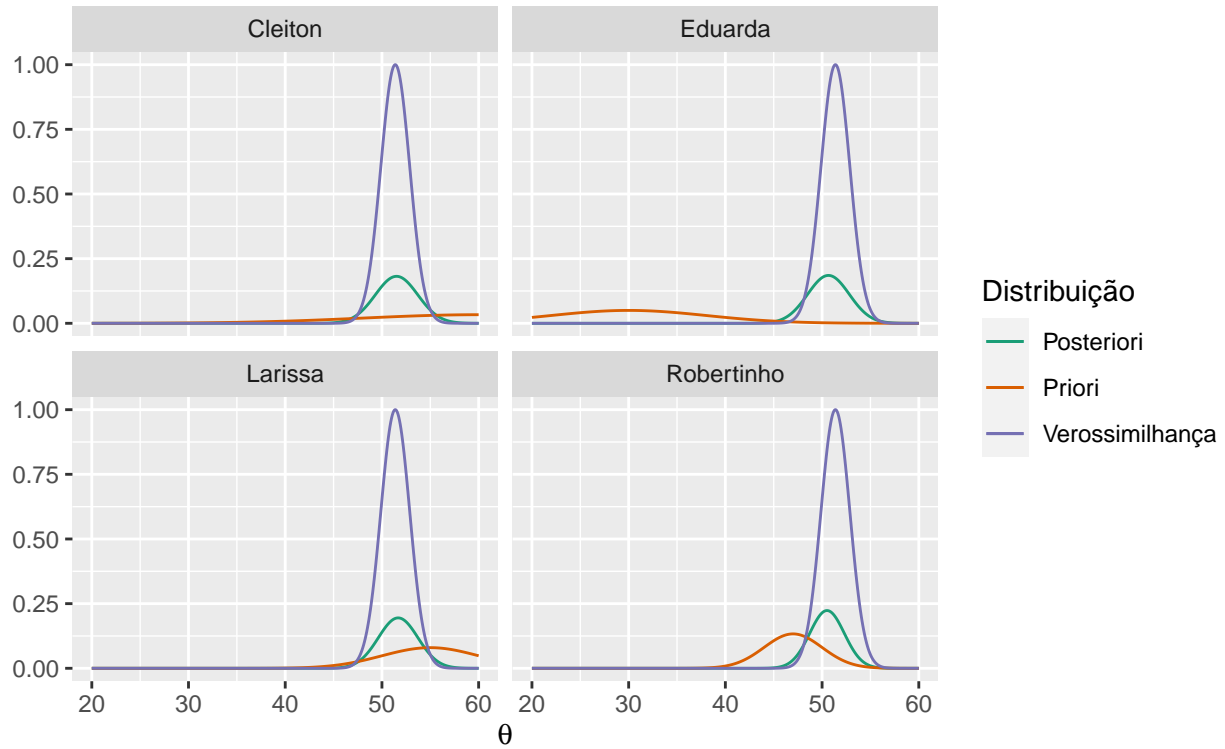
Para a amostra com  $n = 5$  teremos:

```
a <- norm(samp = sample5, sigma = sd(sample), tau0 = 12, mu = 60) %>% mutate(Priori = "Cleiton")
b <- norm(samp = sample5, sigma = sd(sample), tau0 = 8, mu = 30) %>% mutate(Priori = "Eduarda")
c <- norm(samp = sample5, sigma = sd(sample), tau0 = 5, mu = 55) %>% mutate(Priori = "Larissa")
d <- norm(samp = sample5, sigma = sd(sample), tau0 = 3, mu = 47) %>% mutate(Priori = "Robertinho")

rbind(a,b,c,d) %>%
  ggplot(aes(x = theta)) +
  geom_line(aes(y = post, color = "Posteriori")) +
  geom_line(aes(y = priori, color = "Priori")) +
  geom_line(aes(y = ver, color = "Verossimilhança")) +
  scale_colour_brewer(name = "Distribuição", type = "qual", palette = "Dark2")+
  scale_x_continuous(name = expression(theta), limits = c(20, 60))+
  theme(axis.title.y=element_blank()) +
  labs(title = "Distribuições da média do bico dos pinguins",
       subtitle = "n = 5") +
  facet_wrap(~Priori)
```

## Distribuições da média do bico dos pinguins

$n = 5$



```
tibble(
  Prioris = c("Cleiton", "Eduarda", "Larissa", "Robertinho"),
  Media.pri = c(80, 30, 55, 47),
  Media.pos = c(50.6, 43.8, 51.8, 47.5),
  SD.pri = c(12, 8, 5, 3),
  SD.pos = c(22.2, 17.2, 12.1, 6.51),
  IC.025 = c(qnorm(0.025, mean = 50.6, sd = 22.2),
             qnorm(0.025, mean = 43.8, sd = 17.2),
             qnorm(0.025, mean = 51.8, sd = 12.1),
             qnorm(0.025, mean = 47.5, sd = 6.51)),
  IC.975 = c(qnorm(0.975, mean = 50.6, sd = 22.2),
             qnorm(0.975, mean = 43.8, sd = 17.2),
             qnorm(0.975, mean = 51.8, sd = 12.1),
             qnorm(0.975, mean = 47.5, sd = 6.51))) %>%
  knitr::kable(digits = 2, caption = "Resumo aposteriori dos quatro amigos (n=5)")
```

Table 2: Resumo aposteriori dos quatro amigos ( $n=5$ )

| Prioris    | Media.pri | Media.pos | SD.pri | SD.pos | IC.025 | IC.975 |
|------------|-----------|-----------|--------|--------|--------|--------|
| Cleiton    | 80        | 50.6      | 12     | 22.20  | 7.09   | 94.11  |
| Eduarda    | 30        | 43.8      | 8      | 17.20  | 10.09  | 77.51  |
| Larissa    | 55        | 51.8      | 5      | 12.10  | 28.08  | 75.52  |
| Robertinho | 47        | 47.5      | 3      | 6.51   | 34.74  | 60.26  |

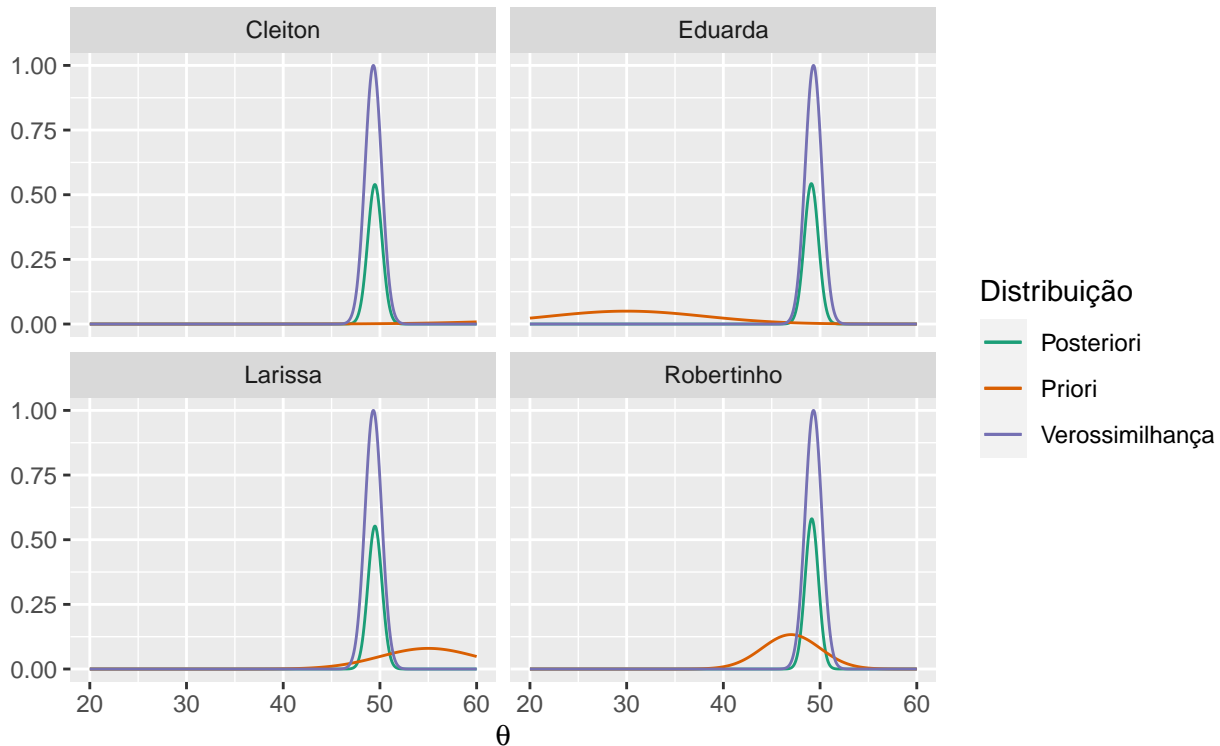
Enquanto que, para  $n = 15$ :

```
e <- norm(samp = sample15, sigma = sd(sample), tau0 = 12, mu = 80) %>% mutate(Priori = "Cleiton")
f <- norm(samp = sample15, sigma = sd(sample), tau0 = 8, mu = 30) %>% mutate(Priori = "Eduarda")
g <- norm(samp = sample15, sigma = sd(sample), tau0 = 5, mu = 55) %>% mutate(Priori = "Larissa")
h <- norm(samp = sample15, sigma = sd(sample), tau0 = 3, mu = 47) %>% mutate(Priori = "Robertinho")

rbind(e,f,g,h) %>%
  ggplot(aes(x = theta)) +
    geom_line(aes(y = post, color = "Posteriori")) +
    geom_line(aes(y = priori, color = "Priori")) +
    geom_line(aes(y = ver, color = "Verossimilhança")) +
    scale_colour_brewer(name = "Distribuição", type = "qual", palette = "Dark2")+
    scale_x_continuous(name = expression(theta), limits = c(20, 60))+
    theme(axis.title.y=element_blank()) +
    labs(title = "Distribuições da média do bico dos pinguins",
         subtitle = "n = 15") +
    facet_wrap(~Priori)
```

## Distribuições da média do bico dos pinguins

n = 15



```
tibble(
  Prioris = c("Cleiton", "Eduarda", "Larissa", "Robertinho"),
  Media.pri = c(80, 30, 55, 47),
  Media.pos = c(49.6, 49.1, 49.5, 49.1),
  SD.pri = c(20, 8, 5, 3),
  SD.pos = c(1.24, 0.735, 0.722, 0.687),
  IC.025 = c(qnorm(0.025, mean = 49.6, sd = 1.240),
             qnorm(0.025, mean = 49.1, sd = 0.735),
```

```

      qnorm(0.025, mean = 49.5, sd = 0.722),
      qnorm(0.025, mean = 49.1, sd = 0.687)),
  IC.975 = c(qnorm(0.975, mean = 49.6, sd = 1.240),
            qnorm(0.975, mean = 49.1, sd = 0.735),
            qnorm(0.975, mean = 49.5, sd = 0.722),
            qnorm(0.975, mean = 49.1, sd = 0.687)))>%
knitr::kable(digits = 2, caption = "Resumo aposteriori dos quatro amigos (n=15)")

```

Table 3: Resumo aposteriori dos quatro amigos (n=15)

| Prioris    | Media.pri | Media.pos | SD.pri | SD.pos | IC.025 | IC.975 |
|------------|-----------|-----------|--------|--------|--------|--------|
| Cleiton    | 80        | 49.6      | 20     | 1.24   | 47.17  | 52.03  |
| Eduarda    | 30        | 49.1      | 8      | 0.74   | 47.66  | 50.54  |
| Larissa    | 55        | 49.5      | 5      | 0.72   | 48.08  | 50.92  |
| Robertinho | 47        | 49.1      | 3      | 0.69   | 47.75  | 50.45  |

## Caso 2: $\mu$ conhecido e $\sigma$ desconhecido

### Distribuições a priori

Seja  $Y_i$  uma amostra aleatória simples de uma distribuição  $Y \sim N(\theta, \sigma^2)$ , com  $\theta$  conhecido.

Primeiramente, vamos encontrar a função de verossimilhança de  $\sigma^2$ .

$$\mathcal{L}(y|\sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma}} e^{-(y_i - \theta)^2 / 2\sigma^2} \propto (\sigma^2)^{-\frac{n}{2}} e^{-\left(\frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \theta)^2\right)}$$

### Priori não informativa

Definimos a log-verossimilhança em nosso caso como sendo:

$$\log(\mathcal{L}(y|\sigma^2)) \propto -\frac{n}{2} \log(\sigma^2) - \sigma^{-2} \sum_{i=1}^n (y_i - \theta)^2$$

A distribuição a *priori* de Jeffreys é dada por  $\pi(\sigma^2) \propto \sqrt{J(\sigma^2)}$ .

$$\begin{aligned}
J(\sigma^2) &\propto E\left(-\frac{\partial^2}{\partial \theta^2} \log(L(\theta))\right) = E\left(-\frac{\partial^2}{\partial \theta^2} \left(-\frac{n}{2} \log(\sigma^2) - (\sigma^2)^{-1} \sum_{i=1}^n (y_i - \theta)^2\right)\right) \\
&= E\left(-\frac{\partial}{\partial \theta} \left(-\frac{n}{2} (\sigma^2)^{-1} + (\sigma^2)^{-2} \sum_{i=1}^n (y_i - \theta)^2\right)\right) = E\left(-\frac{n}{2\sigma^2} + 2(\sigma^2)^{-3} \sum_{i=1}^n (y_i - \theta)^2\right) \\
&= -\frac{n}{2\sigma^2} + 2\sigma^{-4} \sum_{i=1}^n (E(y_i) - \theta)^2 = -\frac{n}{\sigma^2} + 2\sigma^{-4} \sum_{i=1}^n (\theta - \theta)^2 = -\frac{n}{\sigma^2} \propto \sigma^{-2}
\end{aligned}$$

Assim,  $\pi(\sigma) \propto \sqrt{\sigma^{-2}} = \sigma^{-1}$ . Seu parâmetro  $\Phi$  de escala que faz com que  $\theta$  mude somente em locação pode ser obtido através do cálculo de

$$\phi \propto \int \pi(\sigma^2) d\sigma^2 = \int \frac{1}{\sigma^2} d\sigma^2 = \log|\sigma^2| + k \propto \log \sigma^2$$

$\phi$  é uma distribuição imprópria, pois  $\int_0^{+\infty} \log(\sigma^2) d\sigma^2$  é divergente. Assim, a *priori* não favorece nenhuma escala em detrimento de outra.

## Conjugadas Naturais

O suporte de nosso parâmetro de interesse  $\sigma > 0$  permite-nos adotar três distribuições de probabilidade estudadas durante o curso:

### 1. Gama:

Se  $X \sim \text{Gama}(\alpha, \beta)$  então

$$f_X(x|\alpha, \beta) = \frac{\beta^\alpha x^{(\alpha-1)} e^{-\beta x}}{\Gamma(\alpha)} \propto x^{(\alpha-1)} e^{-\beta x}, \quad \alpha > 0, \beta > 0, x > 0$$

### 2. Gama-Inversa:

Se  $X \sim (\alpha, \beta)$  então

$$f_X(x|\alpha, \beta) = \frac{\beta^\alpha x^{-(\alpha+1)} e^{-\beta/x}}{\Gamma(\alpha)} \propto x^{-(\alpha+1)} e^{-\beta/x}, \quad \alpha > 0, \beta > 0, x > 0$$

### 3. Qui-Quadrado:

Se  $X \sim \chi^2(\nu)$  então

$$f_X(x|\nu) = \frac{x^{(\nu/2)-1} e^{-x/2}}{2^{\nu/2} \Gamma(\nu/2)} \propto x^{(\nu/2)-1} e^{-x/2}, \quad \nu > 0, x > 0$$

Note que as duas primeiras estão relacionadas via uma transformação simples e a última é um caso particular delas. Desprezadas as constantes não informativas, as três distribuições são da forma  $x$  elevado a uma potência vezes a exponencial de  $x$ . Dessa forma, as três distribuições servem como conjugada natural da Normal, em nosso caso. Neste trabalho, optou-se por utilizar a distribuição Gama Inversa.

Fazendo  $x = \sigma$ , temos uma *priori* da forma:

$$\sigma^{-(\alpha+1)} e^{-\beta/\sigma^2} \Rightarrow \pi(\sigma) \sim \text{Gama-Inv}(\alpha, \beta)$$

Se quisermos torná-la não informativa, basta utilizarmos  $\alpha \rightarrow 0, \beta \rightarrow 0$ .

## Distribuição a *posteriori*

$$\begin{aligned} \pi(\sigma|y) &\propto \mathcal{L}(y|\sigma^2) \pi(\sigma) = (\sigma^2)^{-\frac{n}{2}} e^{-\left(\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \theta)^2\right)} \sigma^{-(\alpha-1)} e^{-\beta/\sigma^2} \\ &= (\sigma^2)^{-(\alpha + \frac{n}{2} + 1)} e^{-\frac{1}{\sigma^2} \left(\beta + \frac{1}{2} \sum_{i=1}^n (y_i - \theta)^2\right)} \end{aligned}$$

Dessa forma,

$$\pi(\sigma^2|y) \sim \text{Gama-Inv}\left(\alpha + \frac{n}{2}, \beta + \frac{1}{2} \sum_{i=1}^n (y_i - \theta)^2\right)$$



## Exemplo: Comprimento do bico dos pinguins

Cleiton, Eduarda, Larissa e Robertinho estão estudando sobre os Pinguins-de-barbicha. Sabe-se que o comprimento do bico deles tem distribuição Normal com média 48.833 e desvio padrão desconhecido. Os quatro amigos decidem estimar este desvio padrão, cada um define sua *priori* da seguinte forma:

- **Cleiton** nunca viu um pinguim-de-barbicha na vida, nem em fotografia. Dessa forma, ele decide adotar uma *priori* não informativa  $\text{Gama-Inv}(\alpha = 0.01, \beta = 0.01)$
- **Eduarda** sabe tudo sobre pinguins, mas nunca viu um pessoalmente. Ela opta por uma  $\text{Gama-Inv}(\alpha = 20, \beta = 20)$
- **Larissa** adora ir ao zoológico visitar aos pinguins. Ela decide adotar uma  $\text{Gama-Inv}(\alpha = 0.5, \beta = 3)$
- **Robertinho** é um biólogo com muita experiência, que consulta suas anotações sobre pinguins e decide adotar uma *priori*  $\text{Gama-Inv}(\alpha = 35, \beta = 186)$

Chegam duas amostras de bico de pinguins, uma com  $n = 5$ , outra com  $n = 30$ .

```
# gera a priori e a posteriori de uma normal com media conhecida e sigma desconhecido
SigmaNorm <- function(samp, theta = 48.833, alpha = 0.001, beta = 0.001){

  n <- length(samp)
  s <- sum(((samp - theta)/2)^2)

  l_sigma2 <- function(sigma2) sigma2^(-(n/2)) * exp(- 1/sigma2 * s)

  a.post <- alpha + n/2
  b.post <- beta + s

  sigma2 <- seq(0.02, 40, 0.02)

  tibble(sigma2 = sigma2,
          priori = (dinvgamma(sigma2,alpha,beta)),
          post = (dinvgamma(sigma2,a.post,b.post)),
          ver = normalize(l_sigma2(sigma2))/3,
          alpha1 = a.post,
          beta1 = b.post,
          alpha0 = alpha,
          beta0 = beta)
}
```

```
a <- SigmaNorm(sample5, alpha = 0.01, beta = 0.01) %>% mutate(Priori = "Cleiton")
b <- SigmaNorm(sample5,alpha = 1.5, beta = 1.5) %>% mutate(Priori = "Eduarda")
c <- SigmaNorm(sample5,alpha = 0.5, beta = 3) %>% mutate(Priori = "Larissa")
d <- SigmaNorm(sample5,alpha = 34, beta = 186) %>% mutate(Priori = "Robertinho")

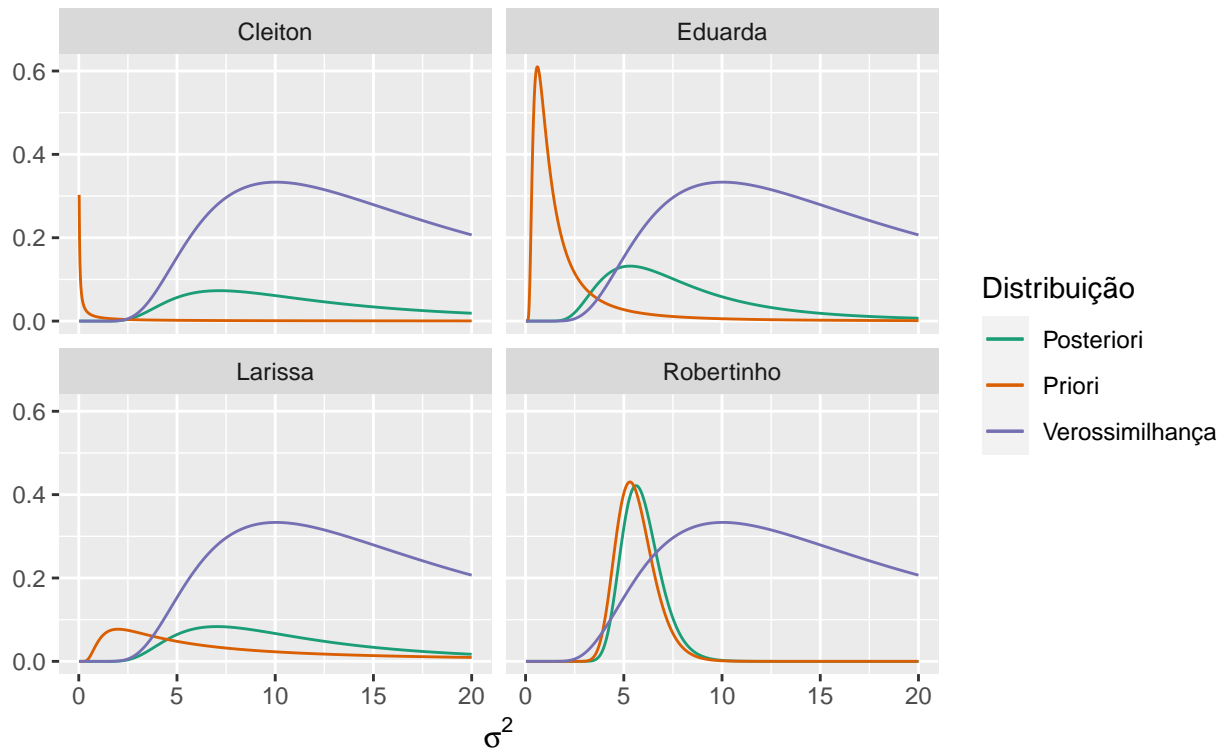
rbind(a,b,c,d) %>%
  ggplot(aes(x = sigma2)) +
  geom_line(aes(y = post, color = "Posteriori")) +
  geom_line(aes(y = priori, color = "Priori")) +
  geom_line(aes(y = ver, color = "Verossimilhança")) +
  #geom_line(aes(y = 0.03* ver, colour = "Verossimilhança")) +
  scale_colour_brewer(name = "Distribuição", type = "qual", palette = "Dark2")+
  scale_x_continuous(name = expression(sigma^2), limits = c(0, 20))+
```

```

theme(axis.title.y=element_blank()) +
labs(
  title = "Distribuições normalizadas da variância do comprimento do bico dos pinguins",
  subtitle = "n=5") +
facet_wrap(~Priori)

```

## Distribuições normalizadas da variância do comprimento do bico dos pinguins n=5



```

tabDesc <- function(alpha, beta){
  tibble( alpha = alpha,
          beta = beta,
          media = beta/(alpha-1),
          var = beta^2/((alpha-1)^2*(alpha-2)),
          moda = beta/(alpha+1),
          IC2.5 = qinvgamma(0.025, alpha, beta),
          IC97.5 = qinvgamma(0.975, alpha, beta))
}

cbind( Priori = c("Cleiton", "Eduarda", "Larissa", "Robertinho"),
       rbind(tabDesc(a$alpha0[1], a$beta0[1]),
             tabDesc(b$alpha0[1], b$beta0[1]),
             tabDesc(c$alpha0[1], c$beta0[1]),
             tabDesc(d$alpha0[1], d$beta0[1])
       )) %>%
knitr::kable(digits = 2, caption = "Resumo a priori (n = 5)")

```

Table 4: Resumo a priori (n = 5)

| Priori     | alpha | beta   | media | var    | moda | IC2.5 | IC97.5        |
|------------|-------|--------|-------|--------|------|-------|---------------|
| Cleiton    | 0.01  | 0.01   | -0.01 | 0.00   | 0.01 | 0.21  | 2.838743e+158 |
| Eduarda    | 1.50  | 1.50   | 3.00  | -18.00 | 0.60 | 0.32  | 1.390000e+01  |
| Larissa    | 0.50  | 3.00   | -6.00 | -24.00 | 2.00 | 1.19  | 6.109550e+03  |
| Robertinho | 34.00 | 186.00 | 5.64  | 0.99   | 5.31 | 4.01  | 7.900000e+00  |

```
cbind( Priori = c("Cleiton","Eduarda", "Larissa", "Robertinho"),
      rbind(tabDesc(a$alpha1[1], a$beta1[1]),
            tabDesc(b$alpha1[1], b$beta1[1]),
            tabDesc(c$alpha1[1], c$beta1[1]),
            tabDesc(d$alpha1[1], d$beta1[1])
      )) %>%
knitr::kable(digits = 2, caption = "Resumo a posteriori (n = 5)")
```

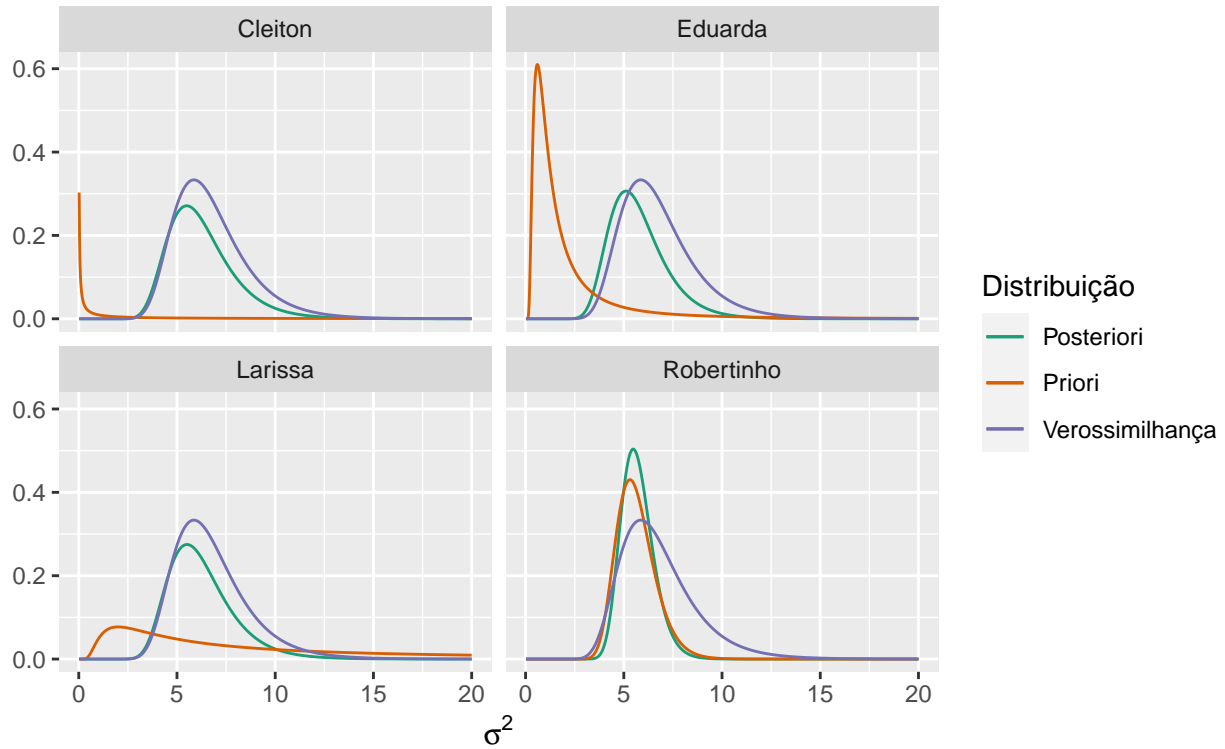
Table 5: Resumo a posteriori (n = 5)

| Priori     | alpha | beta   | media | var    | moda | IC2.5 | IC97.5 |
|------------|-------|--------|-------|--------|------|-------|--------|
| Cleiton    | 2.51  | 25.12  | 16.63 | 542.47 | 7.16 | 3.90  | 59.89  |
| Eduarda    | 4.00  | 26.61  | 8.87  | 39.33  | 5.32 | 3.03  | 24.41  |
| Larissa    | 3.00  | 28.11  | 14.05 | 197.49 | 7.03 | 3.89  | 45.43  |
| Robertinho | 36.50 | 211.11 | 5.95  | 1.03   | 5.63 | 4.29  | 8.24   |

```
a <- SigmaNorm(sample30, alpha = 0.01, beta = 0.01) %>% mutate(Priori = "Cleiton")
b <- SigmaNorm(sample30,alpha = 1.5, beta = 1.5) %>% mutate(Priori = "Eduarda")
c <- SigmaNorm(sample30,alpha = 0.5, beta = 3) %>% mutate(Priori = "Larissa")
d <- SigmaNorm(sample30,alpha = 34, beta = 186) %>% mutate(Priori = "Robertinho")

rbind(a,b,c,d) %>%
  ggplot(aes(x = sigma2)) +
  geom_line(aes(y = post, color = "Posteriori")) +
  geom_line(aes(y = priori, color = "Priori")) +
  geom_line(aes(y = ver, color = "Verossimilhança")) +
  #geom_line(aes(y = 0.03* ver, colour = "Verossimilhança")) +
  scale_colour_brewer(name = "Distribuição", type = "qual", palette = "Dark2")+
  scale_x_continuous(name = expression(sigma^2), limits = c(0, 20))+
  theme(axis.title.y=element_blank()) +
  labs(
    title = "Distribuições normalizadas da variância do comprimeiro do bico dos pinguins",
    subtitle = "n=30") +
  facet_wrap(~Priori)
```

# Distribuições normalizadas da variância do comprimento do bico dos pinguins n=30



```
tabDesc <- function(alpha, beta){
  tibble( alpha = alpha,
          beta = beta,
          media = beta/(alpha-1),
          var = beta^2/((alpha-1)^2*(alpha-2)),
          moda = beta/(alpha+1),
          IC2.5 = qinvgamma(0.025, alpha, beta),
          IC97.5 = qinvgamma(0.975, alpha, beta))
}

cbind( Priori = c("Cleiton","Eduarda", "Larissa", "Robertinho"),
       rbind(tabDesc(a$alpha0[1], a$beta0[1]),
             tabDesc(b$alpha0[1], b$beta0[1]),
             tabDesc(c$alpha0[1], c$beta0[1]),
             tabDesc(d$alpha0[1], d$beta0[1])
       )) %>%
knitr::kable(digits = 2, caption = "Resumo a priori (n = 30)")
```

Table 6: Resumo a priori (n = 30)

| Priori  | alpha | beta | media | var    | moda | IC2.5 | IC97.5        |
|---------|-------|------|-------|--------|------|-------|---------------|
| Cleiton | 0.01  | 0.01 | -0.01 | 0.00   | 0.01 | 0.21  | 2.838743e+158 |
| Eduarda | 1.50  | 1.50 | 3.00  | -18.00 | 0.60 | 0.32  | 1.390000e+01  |

| Priori     | alpha | beta   | media | var    | moda | IC2.5 | IC97.5       |
|------------|-------|--------|-------|--------|------|-------|--------------|
| Larissa    | 0.50  | 3.00   | -6.00 | -24.00 | 2.00 | 1.19  | 6.109550e+03 |
| Robertinho | 34.00 | 186.00 | 5.64  | 0.99   | 5.31 | 4.01  | 7.900000e+00 |

```
cbind( Priori = c("Cleiton", "Eduarda", "Larissa", "Robertinho"),
      rbind(tabDesc(a$alpha1[1], a$beta1[1]),
            tabDesc(b$alpha1[1], b$beta1[1]),
            tabDesc(c$alpha1[1], c$beta1[1]),
            tabDesc(d$alpha1[1], d$beta1[1])
      )) %>%
knitr::kable(digits = 2, caption = "Resumo a posteriori (n = 30)")
```

Table 7: Resumo a posteriori (n = 30)

| Priori     | alpha | beta   | media | var  | moda | IC2.5 | IC97.5 |
|------------|-------|--------|-------|------|------|-------|--------|
| Cleiton    | 15.01 | 87.94  | 6.28  | 3.03 | 5.49 | 3.74  | 10.46  |
| Eduarda    | 16.50 | 89.43  | 5.77  | 2.30 | 5.11 | 3.53  | 9.39   |
| Larissa    | 15.50 | 90.93  | 6.27  | 2.91 | 5.51 | 3.77  | 10.37  |
| Robertinho | 49.00 | 273.93 | 5.71  | 0.69 | 5.48 | 4.30  | 7.56   |